Proyecto parte 3

Segmentacion de Clientes

En esté capitulo nos vamos a enfocar en entender y trabajar un caso de uso para segmentación de clientes, pero antes de eso aquí una pequeña lista de más aplicaciones que se pueden trabajar con los datos recopliados de mis clientes

- Estadística Descriptiva
- Segmentación de Clientes
- Predicción de Abandono
- Valor del Cliente a traves del tiempo (CTLV)

La segmentación la vamos a hacer con base en una metodolgía llamada **RFM**

```
# Importa Pandas, Numpy, Seaborn y Matplotlib
import pandas as pd
import numpy as np
import seaborn as sn
import matplotlib.pyplot as plt
import os
os.chdir("/Users/yair_/OneDrive/Desktop/Ciencia de Datos/proyecto")

# Importa el archivo "Online Retail.csv"
df = pd.read_csv("M30 Online Retail.csv", encoding="unicode_escape")
df
```

	INVOICE_NO	STOCK_CODE	DESCRIPTION	QUANTITY	INVOICE_DATE	UNIT_PRICE	CUSTOMER_ID	REGION
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	01/12/2019 08:26	2.55	17850.0	United Kingdom
1	536365	71053	WHITE METAL LANTERN	6	01/12/2019 08:26	3.39	17850.0	United Kingdom
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	01/12/2019 08:26	2.75	17850.0	United Kingdom
3	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	01/12/2019 08:26	3.39	17850.0	United Kingdom
4	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	01/12/2019 08:26	3.39	17850.0	United Kingdom
...	...	...	...	...	...	...	...	...
541904	581587	22613	PACK OF 20 SPACEBOY NAPKINS	12	09/12/2020 12:50	0.85	12680.0	France
541905	581587	22899	CHILDREN'S APRON DOLLY GIRL	6	09/12/2020 12:50	2.10	12680.0	France
541906	581587	23254	CHILDRENS CUTLERY DOLLY GIRL	4	09/12/2020 12:50	4.15	12680.0	France
541907	581587	23255	CHILDRENS CUTLERY CIRCUS PARADE	4	09/12/2020 12:50	4.15	12680.0	France
541908	581587	22138	BAKING SET 9 PIECE RETROSPOT	3	09/12/2020 12:50	4.95	12680.0	France

541909 rows × 8 columns

```python
# Análisis Exploratorio
import sweetviz as sv
my_report = sv.analyze(df) #pairwise_analysis="off"
my_report.show_html()
```

```
Click to show javascript error.
Report SWEETVIZ_REPORT.html was generated! NOTEBOOK/COLAB USERS: the web browser MAY not pop up, regardless, the report IS saved in your notebook/colab files.
```

Recency

Indicador que nos dice que tan reciente es la compra de un cliente

```python
# Obtener los clientes unicos
customer = df.groupby('CUSTOMER_ID')
```

```python
# Obtener la última fecha de compra por cliente
max_purchase = customer["INVOICE_DATE"].max()
max_purchase
```

```
CUSTOMER_ID
12346.0    18/01/2020 10:17
12347.0    31/10/2020 12:25
12348.0    25/09/2020 13:13
12349.0    21/11/2020 09:51
12350.0    02/02/2020 16:01
                 ...
18280.0    07/03/2020 09:52
18281.0    12/06/2020 10:53
18282.0    09/08/2020 15:10
18283.0    30/11/2020 12:59
18287.0    28/10/2020 09:29
Name: INVOICE_DATE, Length: 4372, dtype: object
```

```python
from datetime import datetime

# Formato de la columna de fechas
formato_entrada = "%d/%m/%Y %H:%M"

# Obtener la fecha y hora actual
fecha_actual = datetime.now()

# Calcular la diferencia para cada fecha
diferencias = []
for fecha_str in max_purchase:
    # Convertir la fecha string a objeto datetime
    fecha_obj = datetime.strptime(fecha_str, formato_entrada)
    # Calcular la diferencia
    diferencia = fecha_actual - fecha_obj
    # Guardar la diferencia
    diferencias.append(diferencia.days)
```

```python
# Vamos a calcular nuestra metrica de Recency, esto lo haremos restando los días de la última fecha de compra a cada observacón
max_purchase = pd.DataFrame(max_purchase)
max_purchase['RECENCY'] = diferencias
max_purchase
```

CUSTOMER_ID	INVOICE_DATE	RECENCY
12346.0	18/01/2020 10:17	1997
12347.0	31/10/2020 12:25	1710
12348.0	25/09/2020 13:13	1746
12349.0	21/11/2020 09:51	1689
12350.0	02/02/2020 16:01	1982
...	...	...
18280.0	07/03/2020 09:52	1948
18281.0	12/06/2020 10:53	1851
18282.0	09/08/2020 15:10	1793
18283.0	30/11/2020 12:59	1680
18287.0	28/10/2020 09:29	1713

4372 rows × 2 columns

```python
# Unir el DataFrame de clientes únicos con el que acabamos de crear de la última fecha de compra
max_purchase.insert(0, "CUSTOMER_ID", max_purchase.index)
max_purchase = max_purchase.reset_index(drop=True)
max_purchase
```

	CUSTOMER_ID	INVOICE_DATE	RECENCY
0	12346.0	18/01/2020 10:17	1997
1	12347.0	31/10/2020 12:25	1710
2	12348.0	25/09/2020 13:13	1746
3	12349.0	21/11/2020 09:51	1689
4	12350.0	02/02/2020 16:01	1982
...	...	...	...
4367	18280.0	07/03/2020 09:52	1948
4368	18281.0	12/06/2020 10:53	1851
4369	18282.0	09/08/2020 15:10	1793

```
# Grafica un histograma de Recency
plt.hist(max_purchase["RECENCY"], bins = 15, ec="black")
plt.xlabel("Días de la última compra")
plt.ylabel("Frecuencia")
plt.title("RECENTY")
plt.show()
plt.clf()
```

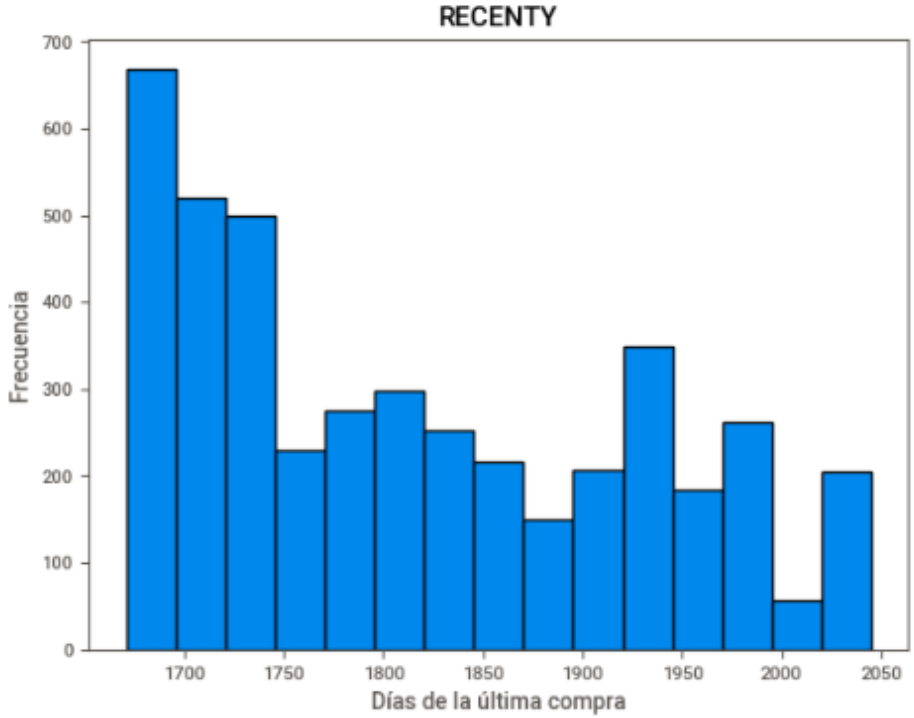


```
<Figure size 640x480 with 0 Axes>
```

```
# Imprime la Estadística de Resumen para Recency
print(max_purchase["RECENCY"].describe())
```

```
count    4372.000000
mean     1815.316560
std       109.483996
min      1671.000000
25%      1716.000000
50%      1792.500000
75%      1912.000000
max      2045.000000
Name: RECENCY, dtype: float64
```

Frequency

Frecuencia con la que un cliente compra uno o más productos

```
# Obtener el número de compras por cliente
frequency = df["CUSTOMER_ID"].value_counts()
frequency = pd.DataFrame(frequency)
frequency = frequency.reset_index()
frequency
```

	CUSTOMER_ID	count
0	17841.0	7983
1	14911.0	5903
2	14096.0	5128
3	12748.0	4642
4	14606.0	2782
...	...	...
4367	15070.0	1
4368	15753.0	1
4369	17065.0	1
4370	16881.0	1
4371	16995.0	1

4372 rows × 2 columns

```
# Unir el DataFrame que acabamos de crear con el de los clientes unicos
customer = pd.merge(max_purchase, frequency, on="CUSTOMER_ID")
customer = customer.rename(columns={'count': 'PURCHASES_QTY'})
customer
```

	CUSTOMER_ID	INVOICE_DATE	RECENCY	PURCHASES_QTY
0	12346.0	18/01/2020 10:17	1997	2
1	12347.0	31/10/2020 12:25	1710	182
2	12348.0	25/09/2020 13:13	1746	31
3	12349.0	21/11/2020 09:51	1689	73
4	12350.0	02/02/2020 16:01	1982	17
...	...	...	...	...
4367	18280.0	07/03/2020 09:52	1948	10

```python
# Grafica un histograma de Frequency
plt.hist(customer["PURCHASES_QTY"], bins = 30, ec="black")
plt.xlabel("Cantidad de compras")
plt.ylabel("Frecuencia")
plt.title("FRECUENCIA DE COMPRA")
plt.show()
```

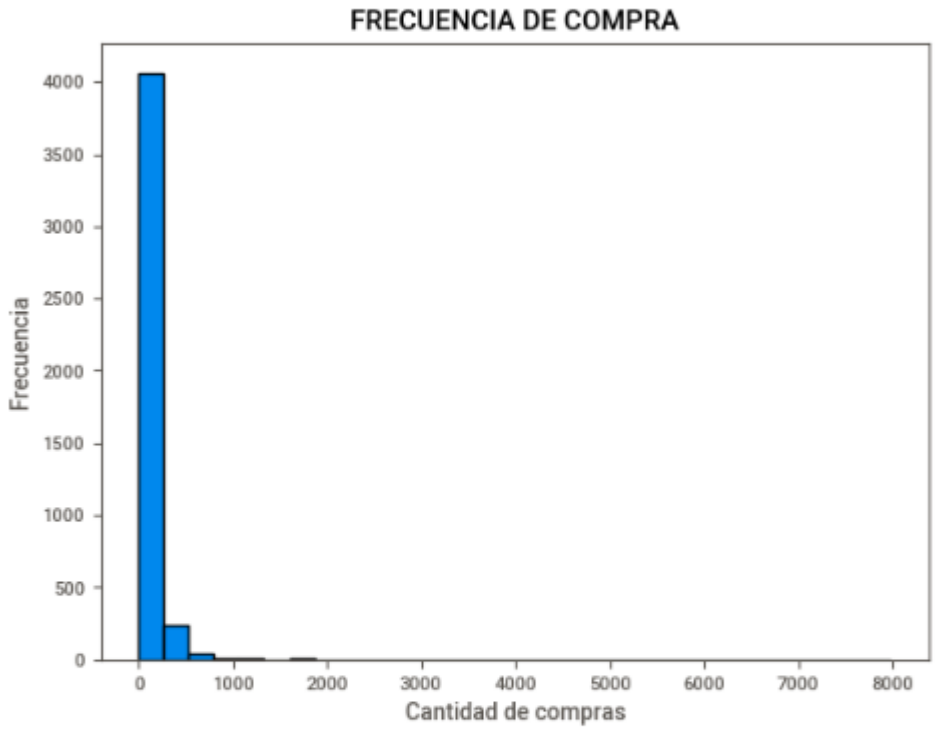


```python
# Imprime la Estadística de Resumen para Frequency
print(customer["PURCHASES_QTY"].describe())
```

```
count    4372.000000
mean       93.053294
std       232.471608
min         1.000000
25%        17.000000
50%        42.000000
75%       102.000000
max      7983.000000
Name: PURCHASES_QTY, dtype: float64
```

Monetary

Valor del monto total que ha gastado un cliente en la compra de mis productos

```
# Calcular el monto total por cada compra
df['MONETARY'] = df["QUANTITY"]*df["UNIT_PRICE"]

# Obtener el valor monetario de compra por cliente
monetary = df.groupby('CUSTOMER_ID')["MONETARY"].sum()
print(monetary)
```

```
CUSTOMER_ID
12346.0       0.00
12347.0    4310.00
12348.0    1797.24
12349.0    1757.55
12350.0     334.40
            ...
18280.0     180.60
18281.0      80.82
18282.0     176.60
18283.0    2094.88
18287.0    1837.28
Name: MONETARY, Length: 4372, dtype: float64
```

```
# Unir el DataFrame que acabamos de crear con el de los clientes unicos
monetary = pd.DataFrame(monetary)
monetary.insert(0, "CUSTOMER_ID", monetary.index)
monetary = monetary.reset_index(drop=True)
customer = pd.merge(customer, monetary, on = "CUSTOMER_ID")
customer
```

	CUSTOMER_ID	INVOICE_DATE	RECENCY	PURCHASES_QTY	MONETARY
0	12346.0	18/01/2020 10:17	1997	2	0.00
1	12347.0	31/10/2020 12:25	1710	182	4310.00
2	12348.0	25/09/2020 13:13	1746	31	1797.24
3	12349.0	21/11/2020 09:51	1689	73	1757.55
4	12350.0	02/02/2020 16:01	1982	17	334.40
...	...	...	...	...	...
4367	18280.0	07/03/2020 09:52	1948	10	180.60
4368	18281.0	12/06/2020 10:53	1851	7	80.82
4369	18282.0	09/08/2020 15:10	1793	13	176.60
4370	18283.0	30/11/2020 12:59	1680	756	2094.88
4371	18287.0	28/10/2020 09:29	1713	70	1837.28

```python
# Grafica un histograma de Monetary
plt.hist(customer["MONETARY"], bins = 20, ec="black")
plt.xlabel("$ por cliente")
plt.ylabel("Frecuencia")
plt.title("VALOR MONETARIO DE COMPRA POR CLIENTE")
plt.show()
```

```python
# Imprime la Estadística de Resumen para Monetary
print(customer["MONETARY"].describe())
```

```
count      4372.000000
mean       1898.459701
std        8219.345141
min       -4287.630000
25%         293.362500
50%         648.075000
75%        1611.725000
max      279489.020000
Name: MONETARY, dtype: float64
```

Algoritmo k-Means

Ya creamos nuestros indicadores principales de la metodología RFM. es hora de hacer *Machine Learning*. Para ello utilizaremos un algoritmo no supervisado llamado **k-Means**

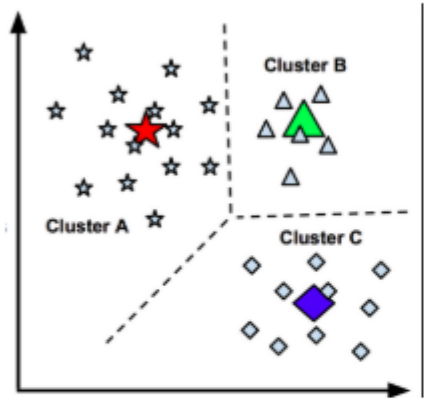


```
# Funcion para ordenar los clusters
def order_cluster(cluster_field_name, target_field_name, df, ascending):
    new_cluster_field_name = 'new_' + cluster_field_name
    df_new = df.groupby(cluster_field_name)[target_field_name].mean().reset_index()
    df_new = df_new.sort_values(by=target_field_name,ascending=ascending).reset_index(drop=True)
    df_new['index'] = df_new.index
    df_final = pd.merge(df,df_new[[cluster_field_name,'index']], on=cluster_field_name)
    df_final = df_final.drop([cluster_field_name],axis=1)
    df_final = df_final.rename(columns={"index":cluster_field_name})
    return df_final
```

Elbow Method

¿Cual es mi número óptimo de clusters? Vamos a contruir una *gráfica de codo* para averiguarlo

```
# Importa la librería de kMeans
from sklearn.cluster import KMeans
```

```python
# Configuración inicial - Vamos a tomar como referencia el indicador de Recency
sse={}

for k in range(1, 10):
    # Instancia el algoritmo de k-means iterando sobre k
    kmeans = KMeans(n_clusters = k, init="k-means++", random_state=2)
    # Entrena el algoritmo
    kmeans.fit(customer[["RECENCY"]])
    # Adunta la inercia o variación al arreglo sse
    sse[k] = kmeans.inertia_

# Grafico de codo (Elbow)
plt.figure(figsize=(12,8))
plt.plot(list(sse.keys()), list(sse.values()))
plt.xlabel("Number of cluster")
plt.show()
```

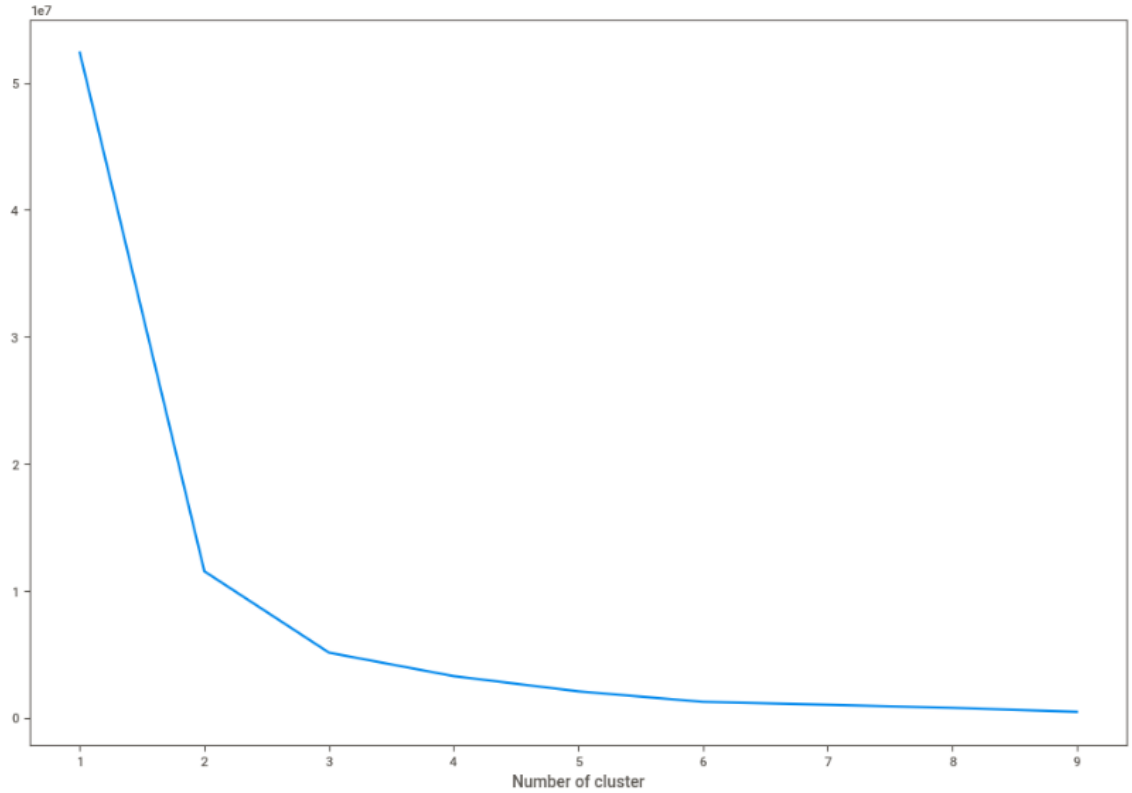

```python
# Instanciar el algoritmo con 4 clusters para Recency
kmeans = KMeans(n_clusters = 4, init="k-means++", random_state=2)
# Entrenar el algoritmo
kmeans.fit(customer[["RECENCY"]])
# Obtener las predicciones
customer['RECENCY_CLUSTER'] = kmeans.fit_predict(customer[["RECENCY"]])

# Ordenar los clusters
customer = order_cluster('RECENCY_CLUSTER', 'RECENCY', customer, False)

# Estadística Descriptiva del cluster creado
customer.groupby("RECENCY_CLUSTER")["RECENCY"].describe()
```

RECENCY_CLUSTER	count	mean	std	min	25%	50%	75%	max
0	711.0	1993.791842	29.790848	1945.0	1968.5	1988.0	2026.0	2045.0
1	1007.0	1894.241311	31.709328	1839.0	1868.0	1897.0	1925.0	1944.0
2	1215.0	1780.455967	31.557607	1741.0	1748.0	1777.0	1806.0	1837.0
3	1439.0	1701.336345	17.721874	1671.0	1685.0	1700.0	1715.0	1739.0

```python
# Instanciar el algoritmo con 4 clusters para Frequency
kmeans = KMeans(n_clusters = 4, init="k-means++", random_state=2)
# Entrenar el algoritmo
kmeans.fit(customer[["PURCHASES_QTY"]])
# Obtener las predicciones
customer['FREQUENCY_CLUSTER'] = kmeans.fit_predict(customer[["PURCHASES_QTY"]])

# Ordenar los clusters
customer = order_cluster('FREQUENCY_CLUSTER', 'PURCHASES_QTY', customer, True)

# Estadística Descriptiva de los clusters
customer.groupby("FREQUENCY_CLUSTER")["PURCHASES_QTY"].describe()
```

FREQUENCY_CLUSTER	count	mean	std	min	25%	50%	75%	max
0	3862.0	49.753755	44.812998	1.0	15.0	34.0	73.0	189.0
1	482.0	329.107884	132.670589	190.0	228.0	286.0	393.5	803.0
2	24.0	1349.750000	508.637759	872.0	1003.5	1156.0	1541.0	2782.0
3	4.0	5914.000000	1473.845537	4642.0	5006.5	5515.5	6423.0	7983.0

```python
# Instanciar el algoritmo con 4 clusters para Monetary
kmeans = KMeans(n_clusters = 4, init="k-means++", random_state=2)
# Entrenar el algoritmo
kmeans.fit(customer[["MONETARY"]])
# Obtener las predicciones
customer['MONETARY_CLUSTER'] = kmeans.fit_predict(customer[["MONETARY"]])

# Ordenar los clusters ¿Como tienes que ordenar el cluster?
customer = order_cluster('MONETARY_CLUSTER', 'MONETARY', customer, True)

# Estadística Descriptiva de los clusters
customer.groupby("MONETARY_CLUSTER")["MONETARY"].describe()
```

MONETARY_CLUSTER	count	mean	std	min	25%	50%	75%	max
0	4332.0	1359.641714	2045.005429	-4287.63	291.0375	640.795	1553.8650	18793.41
1	33.0	37238.807273	14403.896372	19786.44	26763.3400	33350.760	50992.6100	65892.08
2	5.0	129057.952000	36658.292209	88125.38	113384.1400	123725.450	132572.6200	187482.17
3	2.0	267963.755000	16299.186073	256438.49	262201.1225	267963.755	273726.3875	279489.02

Score de Segmentación

El algoritmo de k-means nos da una segmentación generalizada, pero podemos personalizarla aún más creando una métrica que asigne una calificación al valor del cluster. Esto es lo que vamos a hacer!!

```python
# Vamos a crear nuestro score sumando el valor de cada uno de los clusters
customer['SCORE'] = customer["RECENCY_CLUSTER"] + customer["FREQUENCY_CLUSTER"] + customer["MONETARY_CLUSTER"]

# Obtener el promedio para cada una de las métricas de las calificaciones creadas (Score)
customer[["RECENCY_CLUSTER", "FREQUENCY_CLUSTER", "MONETARY_CLUSTER"]].mean()
```

```
RECENCY_CLUSTER      1.773559
FREQUENCY_CLUSTER    0.123971
MONETARY_CLUSTER     0.011208
dtype: float64
```

```python
# Crea una funcion que asigne lo siguiente:
# Si score <= 1 entonces 'Low-Value', si score >1 y <=4 entonces 'Average', si score >4 y <=6 entonces 'Potential', por último si score >6 entonces 'Hig
def segment(score):
    aux = []
    for i in score:
        if i <= 1:
            aux.append("Low-Value")
        elif i > 1 and i <= 4:
            aux.append("Average")
        elif i > 4 and i <= 6:
            aux.append("Potential")
        else:
            aux.append("High-Value")
    return aux


# Crear una columna aplicando esta función al campo 'SCORE'
customer['SEGMENT'] = segment(customer["SCORE"])
```

```python
# Vamos a dar un vistazo a la tabla final
customer.head()
```

	CUSTOMER_ID	INVOICE_DATE	RECENCY	PURCHASES_QTY	MONETARY	RECENCY_CLUSTER	FREQUENCY_CLUSTER	MONETARY_CLUSTER	SCORE	SEGMENT
0	12346.0	18/01/2020 10:17	1997	2	0.00	0	0	0	0	Low-Value
1	12350.0	02/02/2020 16:01	1982	17	334.40	0	0	0	0	Low-Value
2	12356.0	18/01/2020 09:50	1997	59	2811.43	0	0	0	0	Low-Value
3	12361.0	25/02/2020 13:51	1959	10	189.90	0	0	0	0	Low-Value
4	12365.0	21/02/2020 14:04	1963	23	320.69	0	0	0	0	Low-Value

```python
# Imprime la proporción o el total de clientes por segmento
customer.groupby("SEGMENT").count()
```

SEGMENT	CUSTOMER_ID	INVOICE_DATE	RECENCY	PURCHASES_QTY	MONETARY	RECENCY_CLUSTER	FREQUENCY_CLUSTER	MONETARY_CLUSTER	SCORE
Average	2741	2741	2741	2741	2741	2741	2741	2741	2741
High-Value	5	5	5	5	5	5	5	5	5
Low-Value	1608	1608	1608	1608	1608	1608	1608	1608	1608
Potential	18	18	18	18	18	18	18	18	18

```python
# Define un estilo 'bmh'
plt.style.use("bmh")

# Filtra los valores para RECENCY < 4000
customer_filter = customer[customer["RECENCY"] < 4000]

# Crea un grafico de dispersion de 'MONETARY' VS 'RECENCY' por Segmento
plt.scatter(customer_filter["MONETARY"], customer_filter["RECENCY"])
plt.title('Gráfico de Dispersión')
plt.xlabel('Monetary')
plt.ylabel('Recency')
plt.show()
```

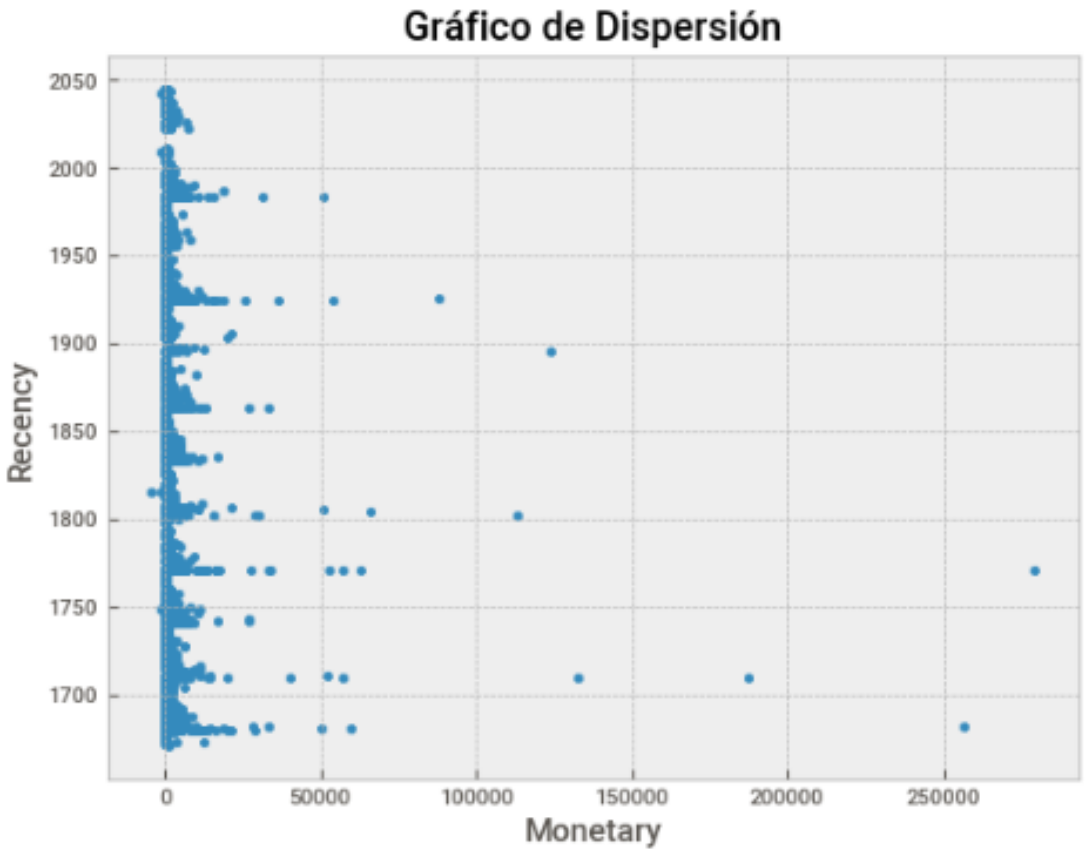
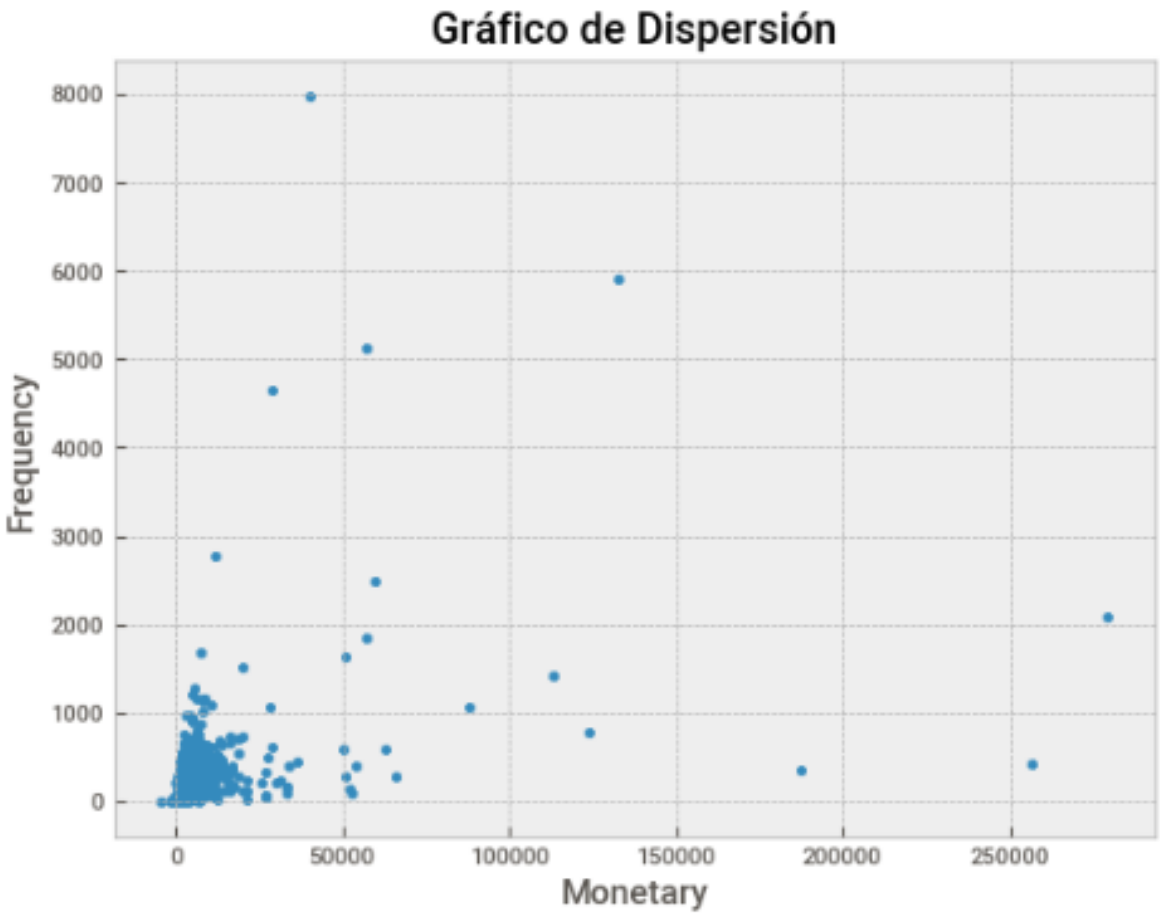
```python
# Crea un grafico de dispersion de 'MONETARY' VS 'FREQUENCY' por Segmento
plt.scatter(customer_filter["MONETARY"], customer_filter["PURCHASES_QTY"])
plt.title('Gráfico de Dispersión')
plt.xlabel('Monetary')
plt.ylabel('Frequency')
plt.show()
```